
**Laporan
Prediksi DropOut Mahasiswa
Menggunakan Machine Learning**



Nama : Muhammad Zacky Rachim

Nim :A11.2024.15953

Kelas : PM A11.4404

**UNIVERSITAS DIAN NUSWANTORO
SEMARANG
2026**

Kata Pengantar

Puji syukur kehadiran Allah SWT atas segala rahmat, taufik, dan hidayah-Nya sehingga penulis dapat menyelesaikan laporan ini dengan baik dan tepat pada waktunya.

Laporan ini disusun sebagai salah satu bentuk pertanggung jawaban akademik sekaligus untuk memenuhi salah satu tugas yang telah ditetapkan. Dalam proses penyusunannya, penulis memperoleh bantuan, bimbingan, serta dukungan dari berbagai pihak sehingga laporan ini dapat diselesaikan dengan baik.

Pada kesempatan ini, penulis menyampaikan ucapan terima kasih kepada semua pihak yang telah memberikan bantuan, arahan, serta dukungan, baik secara langsung maupun tidak langsung, selama proses penyusunan laporan ini.

Penulis menyadari bahwa laporan ini masih memiliki keterbatasan dan jauh dari kata sempurna. Oleh karena itu, penulis mengharapkan kritik dan saran yang bersifat membangun demi penyempurnaan laporan ini di masa yang akan datang.

Akhir kata, penulis berharap semoga laporan ini dapat memberikan manfaat serta menambah wawasan bagi pembaca dan dapat digunakan sebagaimana mestinya.

Semarang, 17 Juli 2026

Muhammad Zacky Rachim

Daftar Isi

Kata Pengantar.....	2
Daftar Isi.....	3
BAB I.....	4
PENDAHULUAN.....	4
1.1 Latar Belakang	4
1.2 Problem Statement.....	4
1.3 Tujuan Proyek	4
1.4 Tujuan Bisnis dan Metrik Kesuksesan.....	5
BAB II.....	6
DATA DAN METODOLOGI.....	6
2.1 Sumber dan Akuisisi Data	6
2.2 Statistik Deskriptif Awal.....	6
2.3 Alur Kerja (Pipeline) Machine Learning	6
2.4 Eksplorasi Data (Exploratory Data Analysis)	7
2.5 Feature Engineering dan Preprocessing.....	8
2.6 Pembagian Dataset (Train-Test Split)	8
BAB III	9
PEMODELAN DAN EVALUASI.....	9
3.1 Model yang Diimplementasikan	9
3.2 Hyperparameter Tuning.....	9
3.3 Metrik Evaluasi.....	9
Classification Report — Model Terbaik.....	10
3.4 Confusion Matrix dan ROC-AUC	10
3.5 Interpretasi Model (Feature Importance)	10
3.6 Pemilihan Model Terbaik	11
BAB IV	12
DEPLOYMENT DAN APLIKASI STREAMLIT	12
4.1 Arsitektur Aplikasi	12
4.2 Dashboard EDA (Eksplorasi Data)	12
4.3 Halaman Model Performance.....	12
4.4 Halaman Prediksi (Model Demo)	12
4.5 Struktur Repository	12
BAB V.....	13
KESIMPULAN DAN REKOMENDASI	13
5.1 Kesimpulan	13
5.2 Rekomendasi Pengembangan Lanjutan	13
DAFTAR PUSTAKA	14

BAB I

PENDAHULUAN

1.1 Latar Belakang

Dropout mahasiswa merupakan salah satu persoalan penting dalam penyelenggaraan pendidikan tinggi. Tingginya angka mahasiswa yang tidak menyelesaikan studi berdampak langsung pada tingkat kelulusan institusi, efisiensi proses pembelajaran, alokasi sumber daya akademik, hingga akreditasi perguruan tinggi. Selama ini identifikasi mahasiswa berisiko dropout umumnya dilakukan secara manual oleh dosen wali atau bagian akademik berdasarkan pengamatan kasar terhadap nilai dan kehadiran, sehingga intervensi baru dilakukan setelah masalah cukup parah dan sulit diperbaiki.

Pendekatan berbasis data dan machine learning memungkinkan institusi mendeteksi pola-pola tersembunyi pada data akademik, sosial-ekonomi, dan demografis mahasiswa sejak semester-semester awal perkuliahan. Dengan model prediktif yang terlatih pada data historis, pihak kampus dapat melakukan intervensi lebih dini terhadap mahasiswa yang teridentifikasi berisiko tinggi, misalnya melalui bimbingan akademik tambahan, keringanan biaya kuliah, atau konseling.

Proyek ini merupakan Capstone Project pada mata kuliah Pembelajaran Mesin yang mengintegrasikan seluruh tahapan pipeline machine learning secara end-to-end: mulai dari akuisisi data, eksplorasi dan preprocessing, pemodelan dan evaluasi, hingga deployment model ke dalam aplikasi yang dapat diakses oleh pengguna non-teknis (dosen wali, bagian akademik, atau pengambil kebijakan kampus).

1.2 Problem Statement

Problem statement yang diangkat adalah: “Bagaimana memprediksi risiko dropout seorang mahasiswa berdasarkan data demografis, sosial-ekonomi, dan performa akademiknya pada satu hingga dua semester pertama, sehingga institusi dapat melakukan intervensi akademik secara lebih dini dan tepat sasaran?”. Permasalahan ini termasuk dalam domain klasifikasi biner (binary classification) dalam machine learning, dengan keluaran berupa label risiko “Dropout” atau “Tidak Dropout” beserta estimasi probabilitasnya.

1.3 Tujuan Proyek

1. Melakukan eksplorasi dan analisis data (EDA) terhadap dataset akademik mahasiswa untuk memahami karakteristik dan pola yang berkaitan dengan dropout.
2. Membangun dan membandingkan beberapa model machine learning untuk memprediksi risiko dropout mahasiswa.
3. Melakukan hyperparameter tuning dan evaluasi model secara komprehensif menggunakan metrik klasifikasi yang relevan.
4. Menyediakan aplikasi dashboard interaktif berbasis Streamlit sebagai media eksplorasi data, evaluasi model, dan prediksi risiko dropout bagi pengguna non-teknis.

1.4 Tujuan Bisnis dan Metrik Kesuksesan

Tujuan bisnis dari proyek ini adalah membantu institusi pendidikan tinggi menekan angka dropout melalui deteksi risiko sejak dini, sehingga program bimbingan dan intervensi akademik dapat lebih tepat sasaran dan efisien dari sisi biaya maupun waktu. Karena kesalahan mengabaikan mahasiswa yang sebenarnya berisiko (false negative) berdampak lebih besar dibandingkan false alarm, metrik kesuksesan proyek difokuskan pada:

- Recall pada kelas Dropout — mengukur seberapa banyak mahasiswa berisiko dropout yang berhasil terdeteksi oleh model.
- F1-Score pada kelas Dropout — sebagai penyeimbang antara precision dan recall mengingat data bersifat tidak seimbang (imbalanced).
- ROC-AUC — mengukur kemampuan model membedakan mahasiswa berisiko dan tidak berisiko secara keseluruhan.
- Accuracy — sebagai metrik pelengkap untuk gambaran umum performa model.

BAB II

DATA DAN METODOLOGI

2.1 Sumber dan Akuisisi Data

Dataset yang digunakan adalah “Predict Students' Dropout and Academic Success” yang tersedia secara publik di UCI Machine Learning Repository. Dataset ini berisi data mahasiswa dari sebuah institusi pendidikan tinggi yang mencakup atribut demografis (status pernikahan, kewarganegaraan, usia), sosial-ekonomi (tingkat pengangguran, inflasi, GDP saat pendaftaran, status beasiswa, status tunggakan biaya kuliah), latar belakang pendidikan (kualifikasi sebelumnya, pendidikan orang tua), serta performa akademik semester 1 dan semester 2 (jumlah mata kuliah yang diambil, disetujui, dievaluasi, dan rata-rata nilai).

Dataset terdiri dari 4.424 baris data mahasiswa dan 37 kolom asli, termasuk kolom target Target yang berisi tiga kategori status akhir mahasiswa: Dropout, Enrolled, dan Graduate. Untuk kebutuhan klasifikasi biner sesuai tujuan proyek, kolom target ditransformasi menjadi kolom baru dropout_risk, dengan aturan: nilai 1 apabila Target = Dropout, dan nilai 0 apabila Target = Graduate atau Enrolled.

2.2 Statistik Deskriptif Awal

Karakteristik	Nilai
Jumlah baris (mahasiswa)	4.424
Jumlah kolom asli	37 (36 fitur + 1 target)
Tipe data fitur	Numerik (int/float), sebagian merupakan kode kategori
Missing value	Tidak ditemukan (0)
Data duplikat	Tidak ditemukan (0), dicek & dibersihkan otomatis pada pipeline
Distribusi target asli	Graduate 49,9% Dropout 32,1% Enrolled 17,9% (perkiraan)
Target penelitian	dropout_risk (0 = Tidak Dropout, 1 = Dropout)

Tabel 2.1 Ringkasan karakteristik dataset

Dataset tidak memiliki missing value maupun baris duplikat berdasarkan hasil pemeriksaan pada tahap preprocessing (data_preprocessing.py), sehingga tidak diperlukan strategi imputasi kompleks. Beberapa kolom seperti Course, Application mode, Mother's/Father's qualification, dan Mother's/Father's occupation merupakan kode kategori yang telah di-encode dalam bentuk numerik oleh penyedia dataset asli.

2.3 Alur Kerja (Pipeline) Machine Learning

Pipeline proyek ini mengikuti alur end-to-end sebagai berikut:

-
1. Data Acquisition — pengunduhan dataset mentah (data/raw/data.csv) dari UCI Machine Learning Repository.
 2. Data Cleaning — pembersihan nama kolom, pengecekan missing value dan duplikat.
 3. Target Engineering — transformasi kolom Target menjadi target biner dropout_risk.
 4. Train-Test Split — pembagian data menjadi data latih dan data uji dengan skema stratified 80:20.
 5. Preprocessing — imputasi median dan standardisasi (StandardScaler) pada seluruh fitur numerik menggunakan ColumnTransformer di dalam sklearn Pipeline.
 6. Modeling — pelatihan beberapa algoritma klasifikasi (Logistic Regression dan Random Forest).
 7. Hyperparameter Tuning — pencarian kombinasi hyperparameter terbaik menggunakan GridSearchCV dengan 5-fold Stratified Cross Validation.
 8. Evaluation — evaluasi model pada data uji menggunakan metrik Accuracy, Precision, Recall, F1-Score, ROC-AUC, dan Confusion Matrix.
 9. Model Selection — pemilihan model terbaik berdasarkan skor F1 dan ROC-AUC.
 10. Deployment — penyimpanan model dan pipeline preprocessing (joblib/pickle), lalu diintegrasikan ke aplikasi Streamlit interaktif.

2.4 Eksplorasi Data (Exploratory Data Analysis)

Eksplorasi data dilakukan melalui dashboard Streamlit pada modul “Eksplorasi Data” yang menyediakan empat jenis visualisasi interaktif:

- Distribusi Fitur — histogram interaktif untuk setiap fitur numerik yang dapat dipilih pengguna, dipisahkan berdasarkan status mahasiswa (Graduate/Dropout/Enrolled), dilengkapi box plot marginal.
- Korelasi — heatmap korelasi antar fitur numerik terhadap target dropout_risk, ditampilkan pula 15 fitur dengan korelasi absolut tertinggi terhadap risiko dropout.
- Box Plot — perbandingan sebaran nilai suatu fitur (misalnya jumlah SKS yang disetujui) antar kategori status mahasiswa untuk mendeteksi outlier dan perbedaan pola.
- Perbandingan Rata-rata — grafik batang perbandingan rata-rata beberapa fitur akademik kunci (jumlah SKS disetujui semester 1 dan 2, rata-rata nilai semester 1 dan 2, usia saat mendaftar) antar kelompok status.

Berdasarkan eksplorasi pada data pelatihan, indikasi awal (insight) yang teramati adalah sebagai berikut:

1. Mahasiswa dengan jumlah mata kuliah yang disetujui (approved) pada semester 1 dan 2 yang rendah cenderung memiliki proporsi dropout yang jauh lebih tinggi dibandingkan mahasiswa dengan jumlah SKS lulus yang tinggi.
2. Rata-rata nilai (grade) semester 1 dan semester 2 berkorelasi negatif dengan risiko dropout — semakin rendah rata-rata nilai, semakin tinggi kecenderungan mahasiswa untuk dropout.
3. Status pembayaran biaya kuliah (Tuition fees up to date) dan status memiliki tunggakan (Debtor) menunjukkan asosiasi yang cukup kuat dengan status dropout, mengindikasikan faktor ekonomi turut berperan penting.

4. Mahasiswa penerima beasiswa (Scholarship holder) menunjukkan proporsi dropout yang lebih rendah dibandingkan yang tidak menerima beasiswa.
5. Usia saat mendaftar (Age at enrollment) yang lebih tua cenderung berasosiasi dengan risiko dropout yang sedikit lebih tinggi, kemungkinan terkait komitmen waktu dan tanggung jawab di luar studi.

2.5 Feature Engineering dan Preprocessing

Tahap preprocessing diimplementasikan pada `src/data_preprocessing.py` dan `src/train_model.py`, dengan langkah-langkah sebagai berikut:

- Target Encoding: kolom Target yang bersifat kategorikal (Dropout/Graduate/Enrolled) ditransformasi menjadi target biner `dropout_risk`.
- Feature Selection: seluruh 36 fitur numerik (termasuk fitur berkode kategori) digunakan sebagai input model.
- Imputasi: SimpleImputer dengan strategi median diterapkan pada seluruh fitur numerik untuk mengantisipasi missing value pada data baru, meskipun data pelatihan tidak memiliki missing value.
- Scaling: StandardScaler diterapkan untuk menstandarisasi skala seluruh fitur numerik, penting khususnya bagi algoritma yang sensitif terhadap skala seperti Logistic Regression.
- Penanganan Ketidakseimbangan Kelas: parameter `class_weight='balanced'` digunakan pada kedua model (Logistic Regression dan Random Forest) untuk mengompensasi proporsi kelas Dropout yang lebih kecil dibandingkan Non-Dropout, tanpa perlu melakukan resampling data secara eksplisit.

Seluruh langkah imputasi dan scaling dibungkus dalam satu objek `ColumnTransformer` yang disatukan ke dalam `sklearn Pipeline` bersama model, sehingga proses preprocessing konsisten diterapkan baik pada saat pelatihan, evaluasi, maupun saat aplikasi Streamlit melakukan prediksi terhadap data baru.

2.6 Pembagian Dataset (Train-Test Split)

Subset	Jumlah Sampel	Jumlah Fitur	Proporsi
Data Latih (Train)	3.539	36	80%
Data Uji (Test)	885	36	20%

Tabel 2.2 Pembagian dataset train dan test (stratified split, random_state = 42)

Pembagian dataset dilakukan menggunakan `train_test_split` dari `scikit-learn` dengan parameter `stratify=y` untuk menjaga proporsi kelas `dropout_risk` tetap seimbang antara data latih dan data uji, serta `random_state=42` agar hasil dapat direproduksi.

BAB III

PEMODELAN DAN EVALUASI

3.1 Model yang Diimplementasikan

Sesuai ketentuan proyek untuk mengimplementasikan minimal dua model berbeda, proyek ini membangun dan membandingkan dua algoritma klasifikasi:

1. Logistic Regression — digunakan sebagai model baseline yang interpretatif dan cepat dilatih, dengan `class_weight='balanced'` dan `max_iter=1000`.
2. Random Forest Classifier — model ensemble berbasis pohon keputusan yang mampu menangkap pola non-linear dan interaksi antar fitur, dilatih dengan `class_weight='balanced'` dan selanjutnya dioptimasi melalui hyperparameter tuning.

3.2 Hyperparameter Tuning

Optimasi hyperparameter dilakukan pada model Random Forest menggunakan GridSearchCV dengan skema 5-fold Stratified K-Fold Cross Validation dan metrik scoring F1-Score, mengingat data bersifat tidak seimbang. Ruang pencarian hyperparameter yang digunakan adalah sebagai berikut:

Hyperparameter	Kandidat Nilai
n_estimators	100, 200
max_depth	None, 10, 15
min_samples_split	2, 5
min_samples_leaf	1, 2

Tabel 3.1 Grid hyperparameter Random Forest

Proses grid search mengevaluasi seluruh kombinasi ($2 \times 3 \times 2 \times 2 = 24$ kombinasi) pada 5 fold, sehingga total 120 kali pelatihan model dilakukan secara otomatis untuk menemukan kombinasi hyperparameter dengan skor F1 rata-rata cross-validation tertinggi.

3.3 Metrik Evaluasi

Karena permasalahan ini adalah klasifikasi biner dengan distribusi kelas yang tidak seimbang (kelas Dropout lebih sedikit dibandingkan Non-Dropout), evaluasi model tidak hanya mengandalkan Accuracy, melainkan menggunakan kombinasi metrik berikut pada data uji (885 sampel):

Model	Accuracy	Precision	Recall	F1-Score	ROC-AUC
Logistic Regression (baseline)	0,8734	0,7866	0,8309	0,8082	0,9277
Random Forest (tuned) — Model Terbaik	0,8780	0,8411	0,7641	0,8007	0,9293

Tabel 3.2 Perbandingan performa model pada data uji (kelas Dropout = 1). *Log output pelatihan Logistic Regression dan Random Forest default dicetak pada konsol saat proses training (`src/train_model.py`),

sedangkan nilai numerik final yang disimpan dan digunakan untuk pemilihan model adalah hasil Random Forest yang telah dituning.

Model terbaik yang dipilih (Random Forest hasil tuning) mencatat akurasi 87,80%, precision kelas Dropout 84,11%, recall 76,41%, F1-Score 80,07%, dan ROC-AUC 92,93% — menunjukkan kemampuan diskriminasi yang sangat baik antara mahasiswa berisiko dan tidak berisiko dropout.

Classification Report — Model Terbaik

Kelas	Precision	Recall	F1-Score	Support
0 — Tidak Dropout	0,8931	0,9318	0,9121	601
1 — Dropout	0,8411	0,7641	0,8007	284
Accuracy			0,8780	885
Macro Avg	0,8671	0,8479	0,8564	885
Weighted Avg	0,8764	0,8780	0,8763	885

Tabel 3.3 Classification report lengkap model Random Forest (tuned) pada data uji

3.4 Confusion Matrix dan ROC-AUC

	Prediksi: Tidak Dropout	Prediksi: Dropout
Aktual: Tidak Dropout	560	41
Aktual: Dropout	67	217

Tabel 3.4 Confusion matrix model terbaik pada 885 data uji

Dari confusion matrix di atas, model berhasil mengidentifikasi dengan benar 217 dari 284 mahasiswa yang benar-benar dropout (true positive), namun masih melewatkan 67 mahasiswa dropout yang diprediksi tidak berisiko (false negative). Di sisi lain, terdapat 41 mahasiswa yang diprediksi berisiko dropout padahal sebenarnya tidak (false positive). Nilai ROC-AUC sebesar 0,9293 mengindikasikan model memiliki kemampuan pemisahan (separability) kelas yang sangat baik, jauh di atas ambang batas acak ($AUC = 0,5$). Visualisasi ROC curve dan confusion matrix interaktif tersedia pada dashboard aplikasi di halaman “Model Performance”.

3.5 Interpretasi Model (Feature Importance)

Interpretasi model dilakukan menggunakan feature importance bawaan dari Random Forest (mean decrease in impurity / Gini importance), yang divisualisasikan dalam bentuk grafik batang horizontal pada dashboard aplikasi (halaman Model Performance, bagian “Feature Importance”). Berdasarkan struktur data dan hasil eksplorasi korelasi, fitur-fitur yang secara konsisten berkontribusi besar terhadap prediksi risiko dropout meliputi jumlah mata kuliah yang disetujui pada semester 1 dan 2 (Curricular units approved), rata-rata nilai semester 1 dan 2 (grade), status pembayaran biaya kuliah (Tuition fees up to date), serta usia saat mendaftar (Age at enrollment).

Sebagai catatan pengembangan lebih lanjut, ketentuan proyek menganjurkan penggunaan pustaka SHAP atau LIME untuk interpretasi model yang lebih mendalam (misalnya menjelaskan kontribusi setiap fitur terhadap prediksi individual). Implementasi saat ini menggunakan feature importance bawaan Random Forest sebagai bentuk interpretasi model secara global; penambahan analisis SHAP

value untuk interpretasi lokal per-mahasiswa merupakan rekomendasi pengembangan pada tahap selanjutnya (lihat Bab V).

3.6 Pemilihan Model Terbaik

Random Forest (hasil hyperparameter tuning) dipilih sebagai model terbaik dengan pertimbangan sebagai berikut:

1. Skor F1 dan ROC-AUC tertinggi dibandingkan Logistic Regression dan Random Forest default, menunjukkan keseimbangan terbaik antara precision dan recall pada kelas minoritas (Dropout).
2. Kemampuan menangkap hubungan non-linear antar fitur akademik dan sosial-ekonomi yang kompleks, yang tidak dapat ditangkap sepenuhnya oleh model linear seperti Logistic Regression.
3. Ketersediaan feature importance bawaan yang memudahkan interpretasi model bagi stakeholder non-teknis.
4. Robust terhadap outlier dan tidak memerlukan asumsi distribusi data tertentu.

Model terbaik beserta pipeline preprocessing-nya disimpan dalam format serialized (`best_model.pkl` dan `preprocessing.pkl` menggunakan `joblib`) agar dapat dimuat langsung oleh aplikasi Streamlit tanpa perlu melatih ulang model.

BAB IV

DEPLOYMENT DAN APLIKASI STREAMLIT

4.1 Arsitektur Aplikasi

Model terbaik yang telah dilatih diintegrasikan ke dalam aplikasi web interaktif berbasis Streamlit yang terdiri atas tiga halaman utama, dirancang agar dapat digunakan langsung oleh stakeholder non-teknis seperti dosen wali atau bagian akademik:

- Data Overview — ringkasan dan eksplorasi dataset.
- Model Performance — visualisasi performa dan interpretasi model.
- Prediksi (Predict Output) — form input data mahasiswa dan hasil prediksi risiko dropout secara real-time.

Aplikasi menggunakan pustaka Plotly untuk visualisasi interaktif, serta styling kustom (CSS) untuk tampilan antarmuka yang profesional dan mudah dipahami.

4.2 Dashboard EDA (Eksplorasi Data)

Halaman eksplorasi data menyediakan empat tab interaktif — Distribusi Fitur, Korelasi, Box Plot, dan Perbandingan — yang memungkinkan pengguna memilih fitur secara dinamis dan melihat bagaimana fitur tersebut berhubungan dengan status dropout mahasiswa, tanpa perlu menulis kode apapun.

4.3 Halaman Model Performance

Halaman ini menampilkan metrik evaluasi model (Accuracy, Precision, Recall, F1-Score, ROC-AUC) dalam bentuk kartu metrik, tabel classification report lengkap, confusion matrix interaktif, kurva ROC, grafik feature importance, serta distribusi probabilitas prediksi pada data uji — memberikan gambaran menyeluruh mengenai kualitas dan keandalan model kepada pengguna.

4.4 Halaman Prediksi (Model Demo)

Halaman prediksi menyediakan form input untuk seluruh 36 fitur mahasiswa (status pernikahan, mode pendaftaran, nilai masuk, status beasiswa, performa akademik semester 1 dan 2, dan seterusnya). Setelah pengguna mengisi data dan menekan tombol “Prediksi”, aplikasi memuat pipeline model tersimpan (preprocessing + Random Forest) dan menampilkan hasil klasifikasi — “Berisiko Dropout” atau “Tidak Berisiko Dropout” — secara langsung di antarmuka.

4.5 Struktur Repository

Struktur proyek disusun mengikuti praktik standar proyek data science/machine learning agar mudah dipahami, direproduksi, dan dikembangkan lebih lanjut. Repository dilengkapi README.md yang menjelaskan deskripsi proyek, latar belakang, tujuan, deskripsi dataset, serta struktur direktori secara lengkap, sehingga memudahkan reviewer atau pengembang lain memahami dan menjalankan ulang proyek ini.

BAB V

KESIMPULAN DAN REKOMENDASI

5.1 Kesimpulan

1. Proyek ini berhasil membangun pipeline machine learning end-to-end untuk memprediksi risiko dropout mahasiswa, mulai dari akuisisi data, EDA, preprocessing, pemodelan, evaluasi, hingga deployment aplikasi interaktif.
2. Dataset yang digunakan (4.424 mahasiswa, 36 fitur) tidak memiliki missing value maupun duplikat, sehingga fokus preprocessing lebih diarahkan pada standardisasi skala fitur dan penanganan ketidakseimbangan kelas melalui `class_weight='balanced'`.
3. Model Random Forest hasil hyperparameter tuning (GridSearchCV, 5-fold Stratified CV) terbukti menjadi model terbaik dengan Accuracy 87,80%, F1-Score kelas Dropout 80,07%, dan ROC-AUC 92,93%, mengungguli baseline Logistic Regression.
4. Fitur-fitur akademik semester 1 dan 2 (jumlah SKS yang disetujui dan rata-rata nilai) serta status pembayaran biaya kuliah teridentifikasi sebagai faktor paling berpengaruh terhadap risiko dropout, sejalan dengan intuisi domain pendidikan.
5. Model dan pipeline preprocessing berhasil di-deploy ke dalam aplikasi Streamlit tiga-halaman yang dapat digunakan oleh stakeholder non-teknis untuk eksplorasi data, evaluasi model, dan prediksi risiko dropout individual secara real-time.

5.2 Rekomendasi Pengembangan Lanjutan

1. Menambahkan analisis interpretasi model berbasis SHAP atau LIME untuk memberikan penjelasan per-individu (local explanation) terhadap setiap hasil prediksi, sehingga dosen wali dapat memahami faktor spesifik yang mendorong risiko dropout seorang mahasiswa tertentu.
2. Mengeksplorasi algoritma ensemble lanjutan seperti XGBoost atau LightGBM serta teknik tuning yang lebih ekstensif (mis. Bayesian Optimization/Optuna) untuk berpotensi meningkatkan recall pada kelas Dropout tanpa mengorbankan precision.
3. Melakukan penanganan ketidakseimbangan kelas dengan teknik resampling tambahan (misalnya SMOTE) sebagai perbandingan terhadap pendekatan `class_weight` yang digunakan saat ini.
4. Melakukan deployment aplikasi ke Streamlit Community Cloud atau platform hosting lain agar dapat diakses secara publik oleh stakeholder, beserta dokumentasi cara penggunaan yang lebih rinci.
5. Menambahkan mekanisme monitoring model (model drift monitoring) untuk memastikan performa model tetap relevan seiring perubahan karakteristik mahasiswa dari tahun ke tahun.
6. Melengkapi dokumentasi presentasi berupa video (YouTube) yang merangkum keseluruhan proyek untuk audiens non-teknis, sesuai ketentuan pengumpulan tugas.

DAFTAR PUSTAKA

Realinho, V., Vieira Martins, M., Machado, J., & Baptista, L. (2021). Predict Students' Dropout and Academic Success [Dataset]. UCI Machine Learning Repository.

Pedregosa, F., et al. (2011). Scikit-learn: Machine Learning in Python. Journal of Machine Learning Research, 12, 2825–2830.

Breiman, L. (2001). Random Forests. Machine Learning, 45(1), 5–32.

Streamlit Inc. (2024). Streamlit Documentation. <https://docs.streamlit.io>

Link Youtube : <https://youtu.be/a5VYqqjJsk?si=gy4gkmUrl-zskgIn>

Link Git Hub : https://github.com/muhammadzackyrachim-pixel/Prediksi-Risiko-Dropout-Mahasiswa_UAS_PM.git